

Clasificador topológico para la detección de ataques epilépticos

Instructores

Dr. Jesús F. Espinoza & Dra. Rosalía G. Hernández

Diplomado Internacional de Modelado Matemático y Simulaciones
Departamento de Matemáticas
Universidad de Sonora

Basado en: Piangerelli, M., Rucco, M., Tesei, L., & Merelli, E. (2018). Topological classifier for detecting the emergence of epileptic seizures. *BMC Research Notes*, 11(1), 392. DOI: [10.1186/s13104-018-3482-7](https://doi.org/10.1186/s13104-018-3482-7)

Objetivos

- **Contexto clínico:** Explicar el problema de la epilepsia y el papel de las señales de EEG.
- **Datos:** Describir la base de datos utilizada (CHB-MIT) y su estructura.
- **TDA:** Introducir las ideas básicas del análisis topológico de datos y la entropía persistente.
- **Flujo de trabajo:** Presentar el *workflow* propuesto por Piangerelli et al., desde el preprocesamiento hasta el clasificador.
- **Resultados e interpretación:** Analizar el rendimiento del clasificador y sus implicaciones.
- **Proyecto:** Conectar estas ideas con el proyecto a desarrollar en el diplomado.

Contexto: la epilepsia y la actividad eléctrica cerebral

El cerebro como sistema complejo

El cerebro humano es un sistema complejo y auto-adaptativo. Su comportamiento emerge de miles de millones de interacciones neuronales no lineales.

¿Qué es la epilepsia?

Es un trastorno cerebral crónico caracterizado por convulsiones recurrentes, resultado de descargas eléctricas excesivas y súbitas. Afecta a unos 50 millones de personas en el mundo (OMS).

La hiper-sincronización

Desde la perspectiva de sistemas complejos, la epilepsia se manifiesta como una **hiper-sincronización** espontánea de la actividad neuronal. Identificar estos patrones globales es crucial para el diagnóstico.

Medición: el electroencefalograma (EEG)

La herramienta estándar

El electroencefalograma (EEG) es la técnica principal para registrar la actividad eléctrica del cerebro. Se colocan electrodos en el cuero cabelludo para medir las diferencias de potencial.

Medición: el electroencefalograma (EEG)




Figura: Visualización de un registro de EEG multicanal.

El desafío del análisis automatizado

El análisis automatizado es un reto. Las señales de EEG son intrínsecamente **no lineales** y **no estacionarias** (sus propiedades cambian con el tiempo), lo que dificulta el uso de métodos tradicionales.

La base de datos utilizada

CHB-MIT Scalp EEG Database (PhysioNet)

Origen y descripción

Los datos provienen del repositorio público **PhysioNet** (accesible mediante herramientas como MNE en Python). La base CHB-MIT fue recolectada en el Children's Hospital Boston.

- **Sujetos:** Pacientes pediátricos con convulsiones intratables.
- **Procedimiento:** Monitoreo tras retirar la medicación para evaluar candidatura a cirugía.

Detalles técnicos del estudio de Piangerelli

- **Muestreo:** 256 Hz. Cada registro tiene 921,600 muestras (aprox. 1 hora).
- **Selección:** Se eligieron 66 registros en total:
 - 33 registros **con** al menos un evento epiléptico.
 - 33 registros **sin** eventos epilépticos (control).

Acceso a los datos: <https://physionet.org/content/chbmit/1.0.0/>

Una nueva perspectiva

Limitaciones de métodos tradicionales

Muchos métodos existentes (e.g., entropía muestral) tienen dificultades con la naturaleza compleja de las señales EEG. A menudo fallan en capturar la información **global** del sistema.

Introduciendo el análisis topológico de datos (TDA)

El TDA (*Topological Data Analysis*) proporciona herramientas para estudiar la “forma” de los datos. Se enfoca en características estructurales globales que son robustas al ruido y a las deformaciones.

La propuesta de Piangerelli et al. (2018)

Utilizar una única característica topológica global para distinguir entre señales sanas y epilépticas, capturando diferencias en la “forma” de la señal que reflejan la dinámica cerebral subyacente.

Conceptos de TDA: complejos simpliciales

De los datos a la forma

Para analizar la forma de los datos, los convertimos en estructuras topológicas llamadas **complejos simpliciales**. Estos se construyen a partir de bloques básicos llamados **símplices**.




Figura: Símplices: Puntos (0), líneas (1), triángulos (2), tetraedros (3). (Adaptado de Piangerelli et al., 2018)

Conceptos de TDA: homología persistente

Contando agujeros

La **homología** cuenta el número de agujeros n -dimensionales en un espacio:

- β_0 : Componentes conectadas.
- β_1 : Ciclos (loops).
- β_2 : Vacíos (voids).

Filtración: viendo los datos a través de una lente

Una **filtración** es una sucesión anidada de complejos simpliciales ($K_0 \subseteq K_1 \subseteq \dots$). Construimos la estructura paso a paso, variando un parámetro (la “lente”).

Homología Persistente (HP)

La HP rastrea las características topológicas a medida que avanzamos en la filtración. Registra cuándo “nace” una característica y cuándo “muere”.

Las características que persisten por mucho tiempo son estructuralmente significativas; las de corta duración suelen ser “ruido topológico”.

Conceptos de TDA: entropía persistente (PE)

Del código de barras al clasificador

La HP genera un **código de barras** (o diagrama de persistencia). Para la clasificación automatizada, necesitamos resumir esta información compleja en una característica numérica única.

Entropía persistente (PE)

La entropía persistente ($\mathcal{H}$) cuantifica la diversidad de las longitudes de las barras (ℓ_i) en el diagrama. Si $p_i = \frac{\ell_i}{\sum_j \ell_j}$ es la longitud relativa de la barra i :

$$H = - \sum_i p_i \log(p_i)$$

(Se usa una versión normalizada $\mathcal{H} \in [0, 1]$).

Intuición: Mide cuán “compleja” o diversa es la estructura topológica de la señal.

- **Alta $\mathcal{H}$:** Distribución más uniforme de las longitudes (estructura compleja).
- **Baja $\mathcal{H}$:** Pocas barras dominantes (estructura más simple/ordenada).

Descripción general

El método propuesto, denominado clasificador topológico lineal (LTC), se divide en tres pasos, aunque el clasificador principal se basa en los dos primeros:

❶ **Paso I: Preprocesamiento de la señal.**

Limpiar y preparar los datos de EEG.

❷ **Paso II: Cálculo de características y clasificación.**

Aplicar TDA a cada señal individual, extraer la entropía persistente y construir el clasificador. (*El núcleo del método*).

❸ **Paso III: Identificación de regiones (análisis espacial).**

Usar otra técnica de TDA (Vietoris-Rips) para entender qué áreas del cerebro están más involucradas.

Paso I: preprocesamiento

Objetivo

Reducir el ruido y la complejidad computacional sin perder la información esencial de la señal.

Acciones realizadas

Para cada uno de los 23 canales:

1 Filtrado de ruido:

- Se aplica un filtro pasa-banda (1-70 Hz) para enfocarse en las frecuencias relevantes.
- Se aplica un filtro “notch” para eliminar la interferencia de la línea eléctrica.

2 Downsampling (submuestreo):

- La computación de la HP es costosa. Se reduce la tasa de muestreo (usando “decimación”, factor 10) para acelerar el análisis (de 921,600 a 92,160 muestras).
- **Crucial:** Este proceso debe preservar la *forma geométrica* general de la señal.

Paso II: TDA en señales 1D (filtración piecewise)

El reto: ¿cómo aplicar TDA a una serie de tiempo 1D?

Necesitamos convertir la señal de EEG (una función lineal por trozos) en un complejo simplicial filtrado.

La solución: filtración piecewise (lower-star filtration)

Se utiliza la amplitud de la señal como el parámetro de filtración.

Intuición: Imaginemos “inundar” el gráfico de la señal desde abajo.

- **Nacimiento (H_0):** Al alcanzar un mínimo local (valle), nace una nueva componente.
- **Muerte (H_0):** Al alcanzar un máximo local (pico) que une dos componentes, una de ellas “muere” (se fusiona).

Paso II: TDA en señales 1D (filtración piecewise)




Figura: Concepto de la filtración basada en los valores de la serie de tiempo. (Adaptado de Piangerelli et al., 2018)

Paso II: el clasificador topológico lineal (LTC)

La característica clave

- 1 Se calcula la entropía persistente ($\mathcal{H}_i$) para cada uno de los 23 canales.
- 2 Se calcula el **promedio** de las 23 entropías persistentes ($\overline{\mathcal{H}}$).

Este valor promedio $\overline{\mathcal{H}}$ es la **única característica** utilizada para entrenar un clasificador lineal supervisado.

Resultados: separación de clases

Efectividad de la entropía persistente promedio ($\overline{\mathcal{H}}$)

Al graficar la $\overline{\mathcal{H}}$ para los 33 pacientes sanos y los 33 epilépticos, se observa una clara separación estadística entre las dos poblaciones.

Resultados: separación de clases




Figura: $\bar{\mathcal{H}}$ para pacientes epilépticos (rojo) y sanos (azul). (Fuente: Piangerelli et al., 2018)

Observación clave

Los pacientes **sanos (azul)** tienen valores de $\bar{\mathcal{H}}$ más altos que los pacientes epilépticos (rojo).

Interpretación de los resultados

¿Qué significa una $\overline{\mathcal{H}}$ más alta en pacientes sanos?

Recordemos la intuición de la entropía persistente:

- Alta $\mathcal{H} \implies$ Estructura topológica compleja/diversa.
- Baja $\mathcal{H} \implies$ Estructura topológica más simple/ordenada.

Hipótesis neurofisiológica

- **Cerebro sano (Alta $\overline{\mathcal{H}}$):** La actividad cerebral normal es rica, compleja y variada. Las señales EEG reflejan esta diversidad en su forma topológica.
- **Epilepsia (Baja $\overline{\mathcal{H}}$):** La epilepsia se caracteriza por la **hiper-sincronización**. Esta sincronización excesiva “ordena” la actividad cerebral, resultando en señales EEG con una forma topológica más simple y, por lo tanto, una menor entropía persistente.

Conclusión

El TDA logra cuantificar la pérdida de complejidad en la señal asociada a la actividad epiléptica.

Resultados: comparación con otros métodos

Comparación con entropía muestral (Sample Entropy)

Los autores compararon el rendimiento de TDA con la entropía muestral, una técnica bien establecida en el análisis de series de tiempo no lineales.

Conclusión de la comparación

La entropía muestral falla en separar las dos clases. Las características topológicas globales capturan información que los métodos tradicionales pasan por alto.

Resultados: comparación con otros métodos




Figura: Entropía muestral promedio. No hay separación clara entre los grupos. (Fuente: Piangerelli et al., 2018)

Resultados: rendimiento del clasificador

Evaluación del clasificador topológico lineal (LTC)


El clasificador basado en $\overline{\mathcal{H}}$ fue evaluado usando validación cruzada (10-fold). El rendimiento se mide usando la curva ROC y el área bajo la curva (AUC). (AUC=1.0 es perfecto).

Resultado clave

El clasificador topológico basado en una sola característica logra una precisión diagnóstica alta (97.2 %).


Resultados: rendimiento del clasificador

Clasificador TDA ($\overline{\mathcal{H}}$)



AUC = 97.2 %

Clasificador entropía muestral



AUC = 62.0 %

Paso III: identificación de regiones cerebrales

Un cambio de perspectiva (análisis espacial)

En el paso III, los autores exploran qué regiones del cerebro están más involucradas, utilizando una técnica de TDA diferente: la **filtración de Vietoris-Rips**.

Metodología

- 1 Se considera el conjunto de 23 señales como una **nube de puntos** en un espacio de alta dimensión (donde la dimensión es el número de muestras $N = 92160$).
- 2 Se define una distancia entre señales (distancia euclidiana estandarizada).
- 3 Se aplica la filtración de Vietoris-Rips para construir complejos simpliciales basados en la proximidad de las señales.
- 4 Se identifican los **generadores** (los sensores/electrodos) que participan en los agujeros persistentes.

Paso III: identificación de regiones cerebrales

Hallazgos preliminares

Los pacientes epilépticos mostraron actividad concentrada en pocos sensores (IDs 1, 2 y 5), mientras que en los pacientes sanos la actividad estaba más distribuida. Esto sugiere que la dinámica de las crisis se concentra en ciertas regiones.

Limitaciones del estudio

Tamaño y naturaleza de la muestra

- El estudio se basa en un número reducido de muestras (66 registros).
- Todos los datos provienen de la misma base de datos (CHB-MIT) y de pacientes pediátricos con epilepsia severa, limitando la generalización.

Aspectos metodológicos

- El método clasifica registros completos (1 hora); no está diseñado para la detección en tiempo real ni para la predicción de crisis inminentes.
- Se utiliza una sola característica global ($\overline{\mathcal{H}}$). Aunque simple y eficaz, podría perder información relevante sobre diferencias específicas entre canales.
- La interpretación neurofisiológica del Paso III (generadores) es preliminar y requiere mayor investigación clínica.

Conclusiones del estudio

Aportación principal

Piangerelli et al. introdujeron un método innovador y altamente eficaz para clasificar señales de EEG utilizando análisis topológico de datos.

Puntos clave

- **Enfoque geométrico:** El análisis de la *forma* de la señal mediante TDA (usando filtración lower-star) revela información crucial sobre la dinámica cerebral.
- **Entropía persistente:** Demostró ser un descriptor global que potencialmente captura la pérdida de complejidad asociada a la epilepsia.
- **Simplicidad y eficacia:** Se logró una clasificación muy alta (AUC 97.2 %) usando un clasificador lineal simple basado en una única característica ($\overline{\mathcal{H}}$).
- **Superioridad:** El enfoque topológico superó significativamente a métodos establecidos como la entropía muestral.

Proyecto 3: Epilepsia

Objetivo 1

Aplicar los conocimientos de TDA para replicar la metodología presentada en el artículo de Piangerelli et al. (2018) (Pasos I y II) utilizando datos reales de EEG de la base CHB-MIT.

Objetivo 2

Investigar si es posible detectar cambios topológicos *antes* del inicio de una crisis, trabajando con ventanas de tiempo más pequeñas (detección temprana).

Libreta para Colab

Recurso disponible en:

[Diplomado Internacional: Modelado Matemático y Simulaciones](#)

Proyecto 3: Epilepsia

Tareas a realizar (implementación en Colab)

- ➊ **Acceso a datos:** Cargar los datos de PhysioNet (usando librerías como `mne`).
- ➋ **Preprocesamiento (Paso I):** Implementar el filtrado y el submuestreo (decimación) de las señales (usando `scipy`).
- ➌ **Análisis TDA (Paso II):**
 - Implementar la filtración lower-star en series 1D.
 - Calcular la homología persistente H_0 (usando librerías como GUDHI, Ripser o Giotto-TDA).
 - Calcular la entropía persistente normalizada ($\mathcal{H}$) y el promedio ($\overline{\mathcal{H}}$).
- ➍ **Clasificación (Paso II):** Analizar la separación de clases.
- ➎ **Análisis temporal:** Proponer e implementar metodologías, basadas en el trabajo de Piangerelli et al. que generen alertas tempranas para anticipar ataques epilépticos.

Preguntas y discusión

Dra. Rosalía G. Hernández

Dr. Jesús F. Espinoza

Universidad de Sonora